



INTRODUCCION AL BIG DATA

Clasificación y verificación de hipótesis

Introducción

Casos, aplicaciones y responsabilidad ética de proyectos de Ciencia de Datos



Temas a tratar

- ¡Desarrollando el producto correcto!
- ¿La compañía está saludable?
- ¡Buscando el fraude!
- ¡La cosecha inteligente!
- ¡Predecir lo impredecible!
- ¿Curando personas con datos?

INTRODUCCION

- ¡Desarrollando el producto correcto!

Muchas empresas realizan experimentos y entregan productos después de evaluar los resultados de todas las opciones y pruebas posibles. Por lo general, los científicos de datos ayudan a diseñar el análisis adecuado para la característica correcta que se probará, identificando las **hipótesis basadas en datos** sobre fenómenos y guiando al equipo del producto a través de la retroalimentación constante utilizando los datos recopilados. Por lo tanto, esta actividad del científico de datos es un rol analítico esencial que debe tomarse, asegurando que los productos correctos salgan al mercado con las características correctas.



¿La compañía está saludable?

Los científicos de datos tienen la capacidad de acceder y entender a la salud de las empresas. Esta actividad es bastante sencilla, ya que los resultados de las operaciones comerciales son datos. Por lo tanto, no es necesario encontrar formas de obtener datos de fuentes complicadas. Por lo general, los datos ya están en los sistemas de información de las empresas, tal vez en almacenes de datos o en Lagos de Datos (Data Lakes)



Evaluar la salud de un producto o de un negocio es bastante “simple”. Por lo general, esto se hace definiendo el éxito del producto o del servicio utilizando primero métricas medibles (KPIs). Esas métricas son monitoreadas continuamente para asegurar que la compañía esté en camino de cumplir el objetivo. Sin embargo, como el mundo no es perfecto (por suerte), siempre habrá valores atípicos (puntos de datos “extraños”) en los que los analistas experimentados (científicos de datos) se centrarán para comprender los factores, las causas y las posibles consecuencias comerciales detrás de esos valores atípicos, generalmente empleando tableros de visualización de datos y/o informes.



¡Buscando el fraude

Imaginemos que un equipo de ciencia de datos revela las razones detrás del repentino crecimiento de una compra de subproductos financieros en particular. Una decisión basada en datos sería actuar de acuerdo con ese análisis y por esa razón específica, y liderar el cambio en la estrategia de cartera, en lugar de ajustar la cartera completa de servicios financieros del banco solo porque se identificó esa tendencia. Las finanzas siempre han estado conectadas con los datos. De hecho, la ciencia de datos y las finanzas van de la mano. Incluso antes de que se naciera el término ciencia de datos, las Finanzas lo estaba usando. Al igual que los bancos han automatizado el análisis de riesgos, las industrias financieras también han utilizado la ciencia de datos para esta tarea.



¿Quién está ahí?

Dos ejemplos fáciles y comprensibles son la introducción de algoritmos de detección de rostros en Google Photos, por ejemplo, que detecta quién está con usted en la imagen, y el excelente sistema de recomendación de Netflix, que muestra al usuario las películas / series que le gustarán basado esto en lo que una persona mira o revisa en esta aplicación.



Los usos que se le puede dar al reconocimiento de rostros son infinitos; solo por mencionar algunas aplicaciones: Determinar la cantidad de personas que entran y salen de un centro comercial. Por ejemplo, se puede usar para desenfocar los rostros de las personas de forma predeterminada por razones de privacidad. En los aeropuertos o áreas restringidas, es posible localizar una cara en un pasaporte u otro documento de identificación para fines de coincidencia de caras.





USOS DEL RECONOCIMIENTO FACIAL QUE DESCONOCES

1. Nuevas formas de pago
2. Acceso al telefono
3. Etiquetado de fotos en Facebook
4. Prevención en temas de salud
5. Identificación en aeropuertos
6. Facilitar la búsqueda de desaparecidos
7. Investigaciones policiales
8. Innovación en coches
9. Seguridad al conducir
10. Publicidad segmentada



¡La cosecha inteligente!

La Ciencia de Datos es parte de prácticamente todas las principales industrias, y la agricultura no es una excepción. Las plagas agrícolas pueden reducir rápidamente las ganancias de un agricultor. Pero, el uso indebido de pesticidas puede tener efectos adversos en las personas, las plantas y otros seres vivos. Afortunadamente, algunas compañías reclutan científicos de datos para ayudarles a desarrollar plataformas orientadas al usuario que analicen cuándo aplicar pesticidas y cuánto usar. Una de ellas es una compañía brasileña llamada Agrosmart. Su tecnología se basa en sensores de Internet de las cosas (IoT) e inteligencia artificial para determinar el tipo de insectos en un cultivo y la cantidad presente. Posteriormente, los agricultores tienen un informe asociado y pueden usarlo para planificar la estrategia adecuada para el manejo de plagas. El objetivo es ayudar a los agricultores a controlar de manera rentable las plagas con un impacto ambiental mínimo.



¿Curando personas con datos?

Solo con buena salud se puede lograr lo que se quiera en la vida. El biólogo evolutivo, Caleb Finch describió que la esperanza de vida temprana en el siglo XIX en Europa y EE. UU era de alrededor de 30 años. ¿Cuál es el escenario hoy? Se espera que la esperanza de vida promedio de las mujeres solo en los EE. UU. sea de 81.2 años y la de los hombres de 76.4 años.



¿Qué causó este gran cambio a lo largo de los años?

Claramente se puede correlacionar con el avance en el campo de la medicina y la tecnología que nos han permitido vivir más tiempo y de manera más saludable. Sin embargo, la Ciencia de Datos está jugando un papel crucial en la industria de la salud. Con un historial médico adecuado de una persona, un médico puede determinar fácilmente la enfermedad correcta por la que está pasando esa persona y lo más importante indicar el tratamiento adecuado e incluso personalizado. Los datos clínicos provienen de notas del médico, resultados de laboratorio e imágenes médicas. Este tipo de datos se recopila casi todos los días y un hospital puede utilizar ciertos algoritmos para analizar los registros de pacientes para identificar a ciertas personas en riesgo de afecciones médicas.



¡Predecir lo impredecible!

El uso del análisis de los grandes volúmenes de big data para determinar el mantenimiento predictivo es uno de los temas más comentados en las áreas de mantenimiento y gestión de activos en la industria de la manufactura. El mantenimiento predictivo se centra en cómo predecir cuándo ocurrirán ciertas condiciones y cuándo fallarán las máquinas. Los sensores en tiempo real instalados en el equipo proporcionan datos en tiempo real que puede alimentar a los modelos predictivos para ayudar a determinar cuándo algo está a punto de fallar o cuál es la vida útil restante de ese equipo. Luego puede programar el mantenimiento en función de esos datos.



¿Crees conocerme?

Cualquier entidad que brinde un servicio o producto es responsable de proporcionarlos de la mejor forma personalizada a sus clientes. A través de la Ciencia de Datos se están empleando una variedad de técnicas para analizar la información del cliente y generar información sobre sus interacciones. Además, se está empezando a confiar en el reconocimiento de voz y el software basado en el procesamiento del lenguaje natural para proporcionar una mejor interactividad a sus usuarios. Con los datos proporcionados por los usuarios, las empresas pueden obtener información procesable de las necesidades de sus clientes, lo que conduciría a un aumento de las ganancias. Esto ayudaría a que las mismas puedan optimizar sus estrategias y proporcionar mejores servicios o productos a sus clientes



¡No te aíslas... intégrate!

Los expertos en educación saben que, si los estudiantes comienzan a sentirse aislados en la universidad y carecen de sistemas de apoyo, esos factores podrían afectar negativamente las tasas de retención. Investigadores de la Universidad de Iowa descubrieron una forma de pensar hacia el futuro que podría detectar qué tan bien los estudiantes encajan con los demás. Examinaron los datos utilizados en casi todas las universidades que tienen establecimientos de comida. Esto sugiere que mirar las interacciones entre los alumnos desde el principio y conectarlas con la probabilidad de graduación futura es posible y más necesario de lo que se pensaba anteriormente. Los datos recopilados a través de estudios como este también podrían ayudar a los representantes de las universidades a ser más proactivos para alentar a los estudiantes de primer año a involucrarse e interactuar con grupos de amigos, ya sea conociendo a personas que viven en sus residencias o en otros lugares



¿Cómo lograr la mejor marca?

A la gente le gusta correr. Las aplicaciones para corredores pueden tomar datos del corredor y analizarlos en comparación con lo datos de otros corredores de todo el mundo, para elaborar un plan específico que se pueda seguir en pasos para alcanzar el objetivo general. Los dispositivos portátiles de hoy ofrecen una variedad de funciones propicias para correr, como monitorear el ritmo cardiaco, la presión arterial, el ritmo de carrera y la distancia de carrera, y todos están conectados con la ayuda de internet. Al comienzo, todos los estudios se centraron en analizar datos sobre maratón, describiendo una variedad de estudios sobre diferentes aspectos de la carrera de maratón, como la influencia de la edad, el género, la experiencia en el rendimiento y el ritmo, y centrándose en los registros de carrera de una amplia gama de maratones de grandes ciudades de todo el mundo.



VIDEO ULTIMAS NOTICIAS DEL BIG DATA

<https://drive.google.com/file/d/1mDemQs4fGFYH11omA1VywHssPvJzHqGe/view?usp=sharing>

9 min

Próximo tema

1-Investigar que es

CRISP-DM

2-Cuales son sus faces?

3-Investigar que es

TDSP

Para que se usa
Quien la lanzo?

Customer
Customer_id
Firstname
Lastname
Postal_code
Age
Gender
Email
Order_id
Product_id
Order
Product_id
Customer_id
Date_time
Remark

Product
Product_id
Product_name
Amount
Price
Description

Invoice
Invoice_id
Customer_id
Order_id
Product_id
Date_time
Status
Total
Remark



Metodología



La metodología, hace referencia al conjunto de procedimientos racionales utilizados para alcanzar el objetivo o la gama de objetivos que rige una investigación científica, una exposición doctrinal o tareas que requieran habilidades, conocimientos o cuidados específicos. [Wikipedia](#)



La **metodología Scrum** es un proceso en que se llevan a cabo un conjunto de tareas de forma regular con el objetivo principal de trabajar de manera colaborativa, es decir, trabajo en equipo. Con este método de trabajo lo que se pretende es alcanzar el mejor resultado de un proyecto determinado. 24 ene. 2019

INTRODUCCION

Hoy en día las plataformas de inteligencia de negocios tienen un rol muy importante en las organizaciones cada vez es más común el que una organización busque roles como ingenieros de datos analista de datos o científicos de datos pues se ha incrementado los proyectos relacionados a estas disciplinas.

A principios de la década de 1990 a medida de que la minería de datos evoluciona de niño a adolescente se lleva mucho tiempo el preparar los datos, **raramente había más de 1 o 2 científicos de datos en la misma habitación** y era mucho más probable que los llamaban **Modeladores Predictivos** ya que este tipo de modelado era de vanguardia en esos días.



METODOLOGIA CRISP-DM



A medida que progresaron los años en 1990 hubo un flujo natural que llevó a la estandarización de todas estas lecciones aprendidas y esto conllevó a una metodología común existen muchas metodologías entre las que destacan dos clips:

CRISP-DM, que son las siglas de Cross-Industry Standard Process for **Data Mining**, es un método probado para orientar sus trabajos de minería de datos. Como metodología, incluye descripciones de las fases normales de un proyecto, las tareas necesarias en cada fase y una explicación de las relaciones entre las tareas.

Esta metodología proporciona un enfoque estructurado para planificar un proyecto de minería de datos y fue tanto su éxito que fue adoptada como un parteaguas para proyectos de ciencia de datos **CRISP-DM** es robusta bien probada práctica flexible y ya ha comprobado su utilidad para resolver problemas comerciales espinosos **CRISP-DM** tiene seis fases



CRISP-DM, Tiene 6 fases:



1. CRISP-DM: Entendimiento del negocio

Esta es la primera fase por donde debe comenzar todo proyecto de minería de datos, comprendiendo en profundidad el problema que se quiere resolver y estableciendo los requisitos y objetivos del proyecto desde una perspectiva empresarial para luego trasladarlos a objetivos técnicos y a un plan de proyecto. En primer lugar, se establece cuáles serán los criterios para medir el éxito en el proyecto, ya sean de tipo cualitativo o cuantitativo. Después, se realiza una evaluación de la situación actual determinando los antecedentes y requisitos del problema, tanto en términos de negocio como de minería de datos. Y por último, se realiza un plan de proyecto donde se tiene en cuenta qué pasos se deben seguir y qué procedimientos se emplearán en cada uno de ellos.



2. CRISP-DM: Comprensión de los datos

Es esta fase se lleva a cabo la recolección y exploración inicial de los datos, con el objetivo de establecer un primer contacto con el problema. Esta fase suele ser crítica en el proyecto dado que un mal entendimiento de los datos tiene como consecuencia un aumento en el tiempo global del proyecto y también reduce las garantías de éxito.

Para llevar a cabo esta fase hay que desarrollar una serie de tareas. La primera es recolectar datos iniciales y adaptarlos a las necesidades del proyecto para su posterior procesamiento. Luego se deben describir formalmente los datos obtenidos: número de instancias (filas) y atributos (columnas), el significado de los atributos y una descripción rigurosa del formato de los datos. Después se exploran los datos aplicando técnicas básicas de estadística descriptiva que revelan propiedades de estos. Por último, se lleva a cabo una verificación de los datos para determinar su consistencia, la cantidad y distribución de los valores nulos o valores fuera de rango que puedan provocar ruido en el modelado posterior.



3. CRISP-DM: Preparación de los datos

La fase de preparación trata de seleccionar, limpiar y generar conjuntos de datos correctos, organizados y preparados para la fase de modelado. Esta es una fase sumamente crítica en un proyecto de minería de datos. Los errores en los datos que se pasan por alto y que no son resueltos en esta fase se trasladan hasta la fase de modelado, lo que genera una reducción en la exactitud de los modelos o incluso, es posible entregar al cliente resultados basados en datos que aún contienen errores no detectados. Por esta razón, esta fase es crucial y generalmente demanda siempre el mayor esfuerzo y tiempo del proyecto, aproximadamente un 75% del tiempo total.



4. CRISP-DM: Modelado


En esta fase se lleva a cabo la creación de modelos de conocimiento a partir de los datos suministrados desde la fase anterior. Estos modelos de conocimiento pueden ser de distintos tipos, por ejemplo, se pueden crear modelos de clasificación o regresión con el objetivo de estimar o inferir el valor de una determinada variable.

Para afrontar esta fase hay que seguir una serie de pautas que nos ayudarán a obtener mejores resultados. Aunque parezca obvio, el primer paso es **seleccionar los algoritmos de modelado** más apropiados al problema. Posteriormente se **genera un plan de prueba**, donde configuramos los valores de los parámetros que se usarán para los algoritmos de aprendizaje automático (machine learning), ya que muchos de estos pueden ser configurados para determinar las características del modelo que se generará. También, se determinan las métricas de evaluación que se calcularán para evaluar la bondad de los modelos. Luego **construimos los modelos**, ejecutando los algoritmos seleccionados sobre los datos preparados con el fin de generar uno o más modelos y calculando las métricas.

Y acabamos **evaluando los resultados**, donde se analizan las métricas de evaluación obtenidas con el fin de conocer la bondad de los modelos generados y garantizar que cumplan con los criterios de éxito definidos al inicio del proyecto.

Modelos de Datos

Relaciona fácilmente las tablas



5. CRISP-DM: Evaluación

Si los modelos obtenidos cumplen con las expectativas de negocio, se procede a la explotación del modelo. Si no, se evalúa en esta fase si se procede a iterar nuevamente sobre los pasos anteriores con el objetivo de encontrar nuevos resultados.


Para ello, se realiza una evaluación formal de los resultados obtenidos en las fases anteriores del proyecto, teniendo en cuenta los criterios de éxito de negocio y explicando las causas que provocaron los grados de éxitos alcanzados y revisando todo el proceso llevado a cabo con el fin de encontrar errores que puedan afectar al éxito.



6. CRISP-DM: Despliegue

¡Es hora de poner el modelo a trabajar! En esta última fase es donde se definen las estrategias para su implementación, monitorización y mantenimiento de los modelos. Esto nos ayudará a observar cualquier comportamiento irregular del sistema y corregirlo de forma que no provoque deficiencias en el servicio del cliente.

Por último se lleva a cabo una revisión final de todo el proceso llevado a cabo en el proyecto, evaluando las acciones realizadas de forma correcta e incorrecta, con el fin de enumerar las lecciones aprendidas en el proyecto.



Enlaces y referencias

- [Guía oficial de la metodología CRISP-DM](#)

METODOLOGIA TDSP



¿Qué es el TDSP?

Proceso de ciencia de datos en equipo

Si combina [Scrum](#) y [CRISP-DM](#) , obtendrá algo que se parece al proceso de ciencia de datos en equipo de Microsoft. Lanzado en 2016, TDSP es "una metodología de ciencia de datos ágil e iterativa para ofrecer soluciones de análisis predictivo y aplicaciones inteligentes de manera eficiente". ([Microsoft, 2020](#)).

Este es un [ciclo de vida](#) moderno de ciencia de datos que incorpora el aspecto de [equipo](#) en la ejecución de proyectos.

Combinando software moderno y prácticas ágiles con el ciclo de vida de la ciencia de datos, TDSP es integral con cuatro componentes principales:

- Una definición del ciclo de vida de la ciencia de datos
- Una estructura de proyecto estandarizada
- Infraestructura y recursos recomendados
- Herramientas y utilidades recomendadas




No sorprende que estos dos usen Microsoft Azure; sin embargo, un equipo podría usar otras pilas de tecnología y aun así adherirse al TDSP.

Capacitación en procesos de ciencia de datos y TDSP

Si está interesado en aprender a usar TDSP y otros marcos para entregar proyectos de ciencia de datos, explore el curso [Jefe de equipo de ciencia de datos](#).

Ciclo de vida de TDSP



Aunque el gráfico del ciclo de vida se ve bastante diferente, el ciclo de vida del proyecto de TDSP es como CRISP-DM e incluye cinco etapas iterativas:

1. **Modelado:** ingeniería de características y entrenamiento de modelos
(combina *modelado* y *evaluación*)

2. **Implementación:** implementar en un entorno de producción



3. **Aceptación del cliente :** validación del cliente si el sistema satisface las necesidades comerciales (una fase no cubierta explícitamente por CRISP-DM)

4. **Comprensión empresarial:** defina objetivos e identifique fuentes de datos



5. **Adquisición y comprensión de** datos : ingiera datos y determine si pueden responder a la pregunta de presentación (combina de manera efectiva la *comprensión* y la *limpieza de datos* de CRISP-DM)



Definición de equipo

TDSP aborda la debilidad de la falta de definición de equipo de CRISP-DM mediante la definición de seis roles:

1. Arquitecto de soluciones
2. Gerente de proyecto
3. Ingeniero de datos
4. Científico de datos
5. Desarrollador de aplicaciones
6. Lider del Proyecto

Microsoft define las tareas y los artefactos relevantes para muchos de los roles del equipo durante cada fase del ciclo de vida del proyecto.

Recursos estandarizados

Microsoft también proporciona documentos de proyectos estandarizados, como cartas de proyectos e informes de datos, infraestructura y recursos para proyectos de ciencia de datos, y herramientas y utilidades para la ejecución de proyectos. El uso de algunos de estos artefactos también se asigna a las cinco fases.



<https://drive.google.com/file/d/1ztdwDpbji1T91izePT9auXIYuJj5SF2U/view?usp=sharing>

Fuente:

<https://docs.microsoft.com/es-es/azure/architecture/data-science-process/overview>

Roles En Datos

Idealmente cada uno de los roles realiza sólo estas tareas. Es muy raro si no imposible encontrar a alguien que domine completamente cada una de estas áreas. Por eso, es mejor contar con un equipo integral para desarrollar proyectos de machine learning o ciencia de datos

	INGENIERÍA DE DATOS	MODELADO	DESPLIEGUE EN PRODUCCIÓN	ANÁLISIS DEL NEGOCIO	INFRAESTRUCTURA IA
DATA SCIENTIST	✓	✓		✓	
ML ENGINEER	✓	✓	✓		
DATA ANALYST	✓			✓	
SOFTWARE ENGINEER - ML	✓	✓	✓		✓
ML RESEARCHER	✓	✓			
SOFTWARE ENGINEER	✓				✓

Conoce más en

Machine Learning
En Espanol.com